

DS Mini Project · DAY 1 모델 전략 수립

ESS 배터리 수명 조기 예측

초기 100사이클 데이터로 Cycle Life를 예측하는 회귀 모델

데이터 : MIT-Stanford Battery Dataset (Severson et al., *Nature Energy* 2019)

Train : Batch1 | Test : Batch2 | 추가 Test : Batch3

울산_2반 · 변현준

INPUT 무엇을 예측하고, 어떤 데이터를 쓰는가

Target : Cycle Life


- 방전용량이 정격의 **80% (0.88Ah)**에 처음 도달한 사이클 수
- ESS 배터리 **교체 판단 기준** (SOH 80%)
- 입력은 **처음 100사이클**만 사용 → 조기 예측

배치	원본	최종	제거 이유
Batch1 (Train)	46	36	EOL 도달 전 기록 종료 10셀
Batch2 (Test)	47	39	수명값 없음 8셀 (특수 실험)
Batch3 (추가)	46	44	수명값 없음 2셀

근거: 정상 셀은 0.880~0.883Ah에서 기록 종료, 제거 셀은 0.91~1.04Ah에서 종료
→ 기록된 수명이 실제보다 짧음

시사점 → 정답이 확실한 셀만 학습·평가에 사용 (불확실한 셀은 장수명을 과소평가하게 만들)

EDA 1 Cycle Life 분포




Q. Test 셀은 Train과 비슷한가?

아니다. Test 대부분이 Train 수명 범위 밖에 있다

근거

- 평균 $\pm$ 표준편차: Train 788 ± 149 / B2 566 ± 222 / B3 $1,060 \pm 314$
- 단수명 (<500): Train 0% vs B2 **72%** · 장수명 (>1,000): B3 **52%**
- 이상치: Train 최단 2셀(534·559)은 **5.4C(80%) 급 속충전**, 충전시간 9.0분(Train 최단)
- 참고: B2는 newstructure 셀(9개, 777~1,186)과 일반 셀(30개, 392~514)로 갈림

시사점 → 범위 밖도 예측하는 **선형 모델** · Train 단수명 1/36 → 분류 불가, **회귀** · 오차를 비율로 다루기 위해 **log 변환**



Q. 열화는 일정한가? 초기 용량으로 수명을 알 수 있나?


**가속된다. 꺾이기 전인
100사이클엔 차이가 거의 없다**

근거 (Batch1)

- 수명 마지막 10% 구간의 감소 속도가 10~20% 구간의 약 25배
- Knee point(빨간 점)는 수명의 약 75% 지점
- 사이클 100까지 용량 1.06~1.10Ah로 셀 간 차이 미미

시사점 → 용량 숫자 대신 knee 이전의 **미세 신호**를 찾아야 함

EDA 3 $\Delta Q(V)$ 곡선



Q. 초기 100사이클에 구별 신호가 있나?


있다. 단수명 셀의 방전 곡선이 훨씬 크게 변한다

근거 (3개 배치 전체, 단수명 32 vs 장수명 31셀)

- 3.0V에서 ΔQ 평균: 단수명 **-0.058** vs 장수명 **-0.018Ah** (약 3배)
- ΔQ 최소값(log): 단수명 -1.24 vs 장수명 -1.64
- ΔQ 분산(log): 단수명 **-3.42** vs 장수명 **-4.25**
- 수명과 상관 $r = -0.84$ (Train)

시사점 → ΔQ 통계량을 핵심 피처로 사용

EDA 4 충전 조건과 수명



Q. 고속 충전은 정말 수명이 짧은가?


C-rate보다 충전 시간이 더 중요하다

근거 (Batch1, 프로토콜 20개)

- 평균 수명 최저 **5.4C(80%) 547** ~ 최고 4.4C(80%) 1,074
- 수명과의 상관: C-rate $\rho = -0.24$ vs 충전시간 $\rho = +0.43$
- 충전시간과 열화속도 상관 $\rho = -0.53$ → 짧게 충전 할수록 빨리 열화

시사점 → C-rate 대신 **충전시간을 보조 피쳐**로 사용, 규제로 영향 제한

EDA 5 상관관계와 다중공선성



Q. 어떤 신호를 믿을 수 있나?

**ΔQ 분산이 가장 강하다.
단, 비슷한 피처가 많다**

근거

- dQ_log_var r = **-0.84** (1위)
- 온도·내부저항은 $|r| < 0.2$
- dQ_log_var $\leftrightarrow$ dQ_log_mean 상관 **0.98**

시사점 → 중복 피처 제거 + L1/L2 규제 (ElasticNet)

SUMMARY EDA 발견 → 모델 전략

EDA 발견	전략 반영
Test가 Train 범위 밖 (EDA 1)	회귀 + log 타깃, 범위 밖 예측 가능한 선형 모델
초기 용량으로 구별 불가 (EDA 2)	곡선 기반 피처 필요
ΔQ 에서 차이 뚜렷 (EDA 3)	ΔQ 통계량을 핵심 피처로
C-rate 상관 약함, 충전시간은 열화속도와 연관 (EDA 4)	충전시간을 보조 피처로, 규제에 영향 제한
피처 간 상관 최대 0.98 (EDA 5)	중복 제거 + ElasticNet

결론 → ΔQ 중심 피처 6개 → log(수명) 회귀 → **ElasticNet + LightGBM Voting**

전략 ① Feature Engineering

선택 피처	r	의미
dQ_log_var	-0.84	ΔQ 분산 (핵심)
dQ_at_2V	+0.69	저전압 구간 ΔQ
chargetime_mean_5	+0.57	충전 속도 (보조)
dQ_log_min	-0.55	ΔQ 최대 하락폭
dQ_skew	-0.51	ΔQ 곡선 모양
QD_slope_91_100	+0.44	초기 열화 속도

선별 기준 (Train만 사용)

- 상관 $|r| \geq 0.4$
- 서로 $|r| > 0.85$ 면 하나만
- 사이클 100 이하로 계산

제외

- dQ_log_mean (중복 0.98)
- 온도·내부저항 ($|r| < 0.2$)

근거 → ΔQ 는 용량 숫자가 변하기 전의 **내부 열화**를 포착 (EDA 2·3)

전략 ② Regression 선택 · Target = $\log_{10}(\text{Cycle Life})$ 논문은 두 방식 모두 수행 → 과제는 하나만 선택

	회귀 (선택)	분류
원 논문	처음 100사이클 → MAPE 9.1%	처음 5사이클 → 정확도 95.1%
예측 대상	수명 (사이클 수)	550 이상 여부
Train 상황	36셀 모두 활용	단수명 1셀뿐 → 학습 불가
함정	—	"전부 장수명"만 답해도 정확도 97%
ESS 활용	교체 시점 계획	양/불 판정만

log 변환 이유 (Train 기준)

- 수명 왜도 0.29 → **-0.01** (대칭화)
- 핵심 피처와 선형성 개선: r -0.818 → **-0.837**
- log 오차 $\approx$ 비율 오차 → MAPE와 일치

평가 지표

- MAPE (목표 9.1%, 원 논문)
- RMSE (사이클 단위 보조)

전략 ③ Modeling Strategy — 후보 모델

후보 모델	선정 이유 (EDA 연결)
① 선형회귀 (ΔQ 분산 1개)	Baseline — 가장 강한 신호만으로도 기준선 (EDA 5)
② ElasticNet	범위 밖 예측 가능 (EDA 1) + 다중공선성 대응 (EDA 5)
③ LightGBM	가속형 열화 같은 비선형 포착 (EDA 2) · 단, 범위 밖 예측 불가
④ Voting (②+③)	두 모델의 약점을 서로 보완 → 최종 후보

데이터 처리

- 미완료·수명 없는 셀 제거 (INPUT)
- 0.5Ah 이하 오류 제거, 노이즈 보정
- 사이클 100 이하만 사용, 표준화

검증 (데이터 역할)

- Batch1 → Train 80% (5-fold CV) / Valid 20%
- **Test = Batch2**, 추가 = Batch3 (학습·튜닝 미사용)

딥러닝 미사용

- Train 36셀 → 과적합 위험
- ΔQ 로 이미 강한 신호 확보